



Pourquoi le seuil de dédoublonnage sémantique est fixé à 0,85

Lors de la génération des questions, chaque candidate est comparée aux questions déjà retenues par similarité cosinus de leurs embeddings (modèle text-embedding-3-small). Une candidate dont la similarité avec une question retenue **dépasse 0,85 est rejetée** comme paraphrase. Ce document vérifie, sur de vraies questions générées comme en production, que 0,85 est le bon compromis entre « attraper les paraphrases » et « ne pas éliminer des questions réellement différentes ».

Protocole

Deux jeux réels générés le 08/09/2026 par le module de génération (même modèle et mêmes consignes qu'en production) : **clinique dentaire · Casablanca · français** (24 candidates, 276 paires) et **dental clinic · Muscat · anglais** (25 candidates, 300 paires). Pour chaque paire, similarité cosinus calculée ; on compte les paires qui seraient rejetées à trois seuils, puis on lit les paires proches du seuil pour juger, à l'œil humain, si elles sont de vraies paraphrases ou des questions différentes.

Résultat 1 · nombre de paires rejetées selon le seuil

Seuil	Casablanca · FR (276 paires)	Muscat · EN (300 paires)	Lecture
0,85 (actuel)	5 rejetées	1 rejetée	ne touche que les paraphrases
0,80	14 rejetées	8 rejetées	commence à éliminer des questions distinctes
0,75	44 rejetées	37 rejetées	une paire sur six à sept : perte de diversité

Résultat 2 · les paires proches du seuil, lues une par une

Cosinus	Question A	Question B	Jugement humain
0,915	Je cherche un dentiste spécialiste des enfants à Casablanca, avez-vous des recommandations ?	Je suis parent et je cherche un dentiste pour mes enfants à Casablanca, des suggestions ?	Paraphrase → rejet correct à 0,85
0,899	Je cherche un dentiste spécialiste des enfants à Casablanca...	Est-ce que quelqu'un connaît un dentiste à Casablanca qui est bon avec les enfants ?	Paraphrase → rejet correct à 0,85
0,916	What time do dental clinics in Muscat usually open on weekends?	What are the opening hours of dental clinics in Muscat during the week?	Quasi-doublon (horaires) → rejet correct à 0,85
0,855	Quelles sont les meilleures cliniques dentaires près de moi avec de bons avis ?	Quelle clinique dentaire près de moi a les meilleures critiques en ligne ?	Paraphrase → rejet correct à 0,85
0,851	Quelle est la meilleure clinique dentaire à Casablanca ?	Je veux faire une couronne dentaire, où devrais-je aller à Casablanca ?	Cas limite : intentions différentes, rejeté de justesse à 0,85 (seul faux rejet observé)
0,844	Je veux faire une couronne dentaire, où devrais-je aller à Casablanca ?	Je veux un dentiste qui utilise des techniques modernes, où puis-je aller ?	Différentes → gardées à 0,85, mais rejetées à 0,80

0,843	Where can I find a dental clinic in Muscat that offers emergency services?	I need a dental office in Muscat that can handle urgent tooth pain. Who should I contact?	Même intention (urgence) formulée autrement : cas limite acceptable
0,819	Can I find a dental clinic in Muscat that takes my health insurance?	Can I find a dental clinic in Muscat that offers flexible payment plans?	Différentes (assurance vs facilités de paiement) → rejetées à tort à 0,80
0,806	Where can I find a dental clinic in Muscat that offers emergency services?	Can I find a dental clinic in Muscat that takes my health insurance?	Clairement différentes → rejetées à tort à 0,80
0,800	What are the best dental clinics in Muscat for families with kids?	Which dental clinic has the best reviews in Muscat for cosmetic dentistry?	Clairement différentes → rejetées à tort à 0,80
0,29-0,40	Quel est le coût d'un examen dentaire de routine à Casablanca ?	Où trouver une clinique dentaire qui s'occupe aussi des urgences près de chez moi ?	Paires les plus éloignées : diversité bien présente dans le jeu

Conclusion. La similarité cosinus n'est pas un « pourcentage de ressemblance » au sens courant : deux questions du même secteur et de la même ville partagent déjà 0,70 à 0,80 par le seul contexte. À 0,85, le filtre rejette les vraies paraphrases (0,86 à 0,92) et ne produit qu'un faux rejet limite sur 576 paires ; à 0,80, il éliminerait des questions d'intentions différentes (urgence / assurance / paiement / esthétique), c'est-à-dire exactement la diversité qui fait la valeur de la mesure. **Le seuil 0,85 est conservé.** Il est réglable par configuration (variable DEDUP_THRESHOLD) si un futur jeu de données justifiait de l'ajuster ; toute modification sera précédée du même test.